

PEC 1 Análisis Multivariante

Adriana González Palomo

2025-04-30

Contenidos

Ejercicio 1: Estadística descriptiva inicial	1
Ejercicio 2: PCA	4
Ejercicio 3: MDS clásico	8
Ejercicio 4: MDS no métrico de Kruskal	10
Ejercicio 5: MDS no métrico de Sammon	13
Ejercicio 6: <i>Projection Pursuit</i>	15
Ejercicio 7: MDS métrico con distancia ji-cuadrado	17
Ejercicio 8: Análisis de correspondencias	19
Ejercicio 9: Conclusiones	21
Bibliografía	21
Apéndice	22

Ejercicio 1: Estadística descriptiva inicial

(a) Los datos son recuentos de 0 a 32. Calcular los totales por virus que llamaremos `total_residue`. Dar el recorrido de esta variable.

```
load(file = "virus.rda")  
  
# Calculamos totales por virus  
(total_residue <- rowSums(virus[1:(ncol(virus) - 1)]))
```

```
## 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20  
## 187 190 190 178 179 177 178 176 180 158 122 158 157 156 158 158 160 157 157 159  
## 21 22 23 24 25 26 27 28 29 30 31 32 33 34 35 36 37 38 39 40  
## 160 161 158 158 158 159 158 158 158 158 158 158 158 158 160 158 151 158 158 158  
## 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58 59 60  
## 158 156 152 156 156 158 156 148 228 231 227 230 230 230 198 170 212 226 222 228  
## 61  
## 224
```

```
# Recorrido variable
range(total_residue)
```

```
## [1] 122 231
```

```
range(total_residue)[2] - range(total_residue)[1] # max - min
```

```
## [1] 109
```

(b) Calcular las medias para cada aminoácido.


```
round(colMeans(virus[1:(ncol(virus) - 1)]), 3)
```

```
##      V1      V2      V3      V4      V5      V6      V7      V8      V9      V10     V11
## 20.311 13.672 15.410 17.803  9.410  9.967 17.164  0.869 12.475  1.393  7.492
##      V12     V13     V14     V15     V16     V17     V18
## 14.115  5.590  7.738  1.475  4.934 11.262  2.557
```

(c) Dibujar el histograma de la figura 3. Para ello habrá que fijar las marcas de clase en algunos valores como 120, . . . , 160, . . . , 180, . . . y además un ancho de barra de 5. Cualquier otra configuración distorsiona el histograma que resulta un gráfico poco robusto.


```
df <- data.frame(total_residue, "virus_group" = virus$type)

ggplot(df, aes(x = total_residue)) +
  geom_histogram(color="white", fill = "darkgray", binwidth = 5) +
  theme_classic() + theme(axis.title.y=element_blank()) +
  scale_x_continuous(breaks = c(120, 140, 160, 180, 200, 220, 240)) +
  coord_cartesian(xlim = c(120, 240)) +
  scale_y_continuous(breaks = c(0, 5, 10, 15, 20, 25)) +
  xlab("total residue")
```



(d) Dibujar el diagrama de cajas (boxplot) de la figura 3. Identificar el valor atípico más destacado del grupo de los Furovirus.

```
ggplot(df, aes(x = virus_group, y = total_residue)) +
  geom_boxplot(outlier.shape = "-") +
  theme_bw() + theme(panel.grid.major = element_blank(),
panel.grid.minor = element_blank()) +
  xlab("virus group") + ylab("total residue")
```



Dentro del grupo de los Furovirus, se observa un valor atípico con un total de residuos de 170, el cual se encuentra notablemente por debajo de la media del grupo y fuera del rango intercuartílico, tal como se muestra en el boxplot.

(e) Dividir la variable `total_residue` en una partición de cuatro intervalos de forma que podamos clasificar los tipos de virus perfectamente, excepto un único virus extraño.

```
categories <- unique(df$virus_group) # Grupos de virus

for (category in categories){
  cat(category, ": ", range(df$total_residue[df$virus_group == category]), "\n")
}
```

```
## Hodr : 187 190
## Tobr : 176 180
## Toba : 122 161
## Furo : 170 231
```

```
# Definimos partición de los intervalos
breaks <- c(120, 165, 185, 195, 240)

# Creamos las clases
df$class <- cut(df$total_residue, breaks = breaks)

head(df, 5)
```

```
##   total_residue virus_group   class
## 1          187         Hodr (185,195]
## 2          190         Hodr (185,195]
## 3          190         Hodr (185,195]
## 4          178         Tobr (165,185]
## 5          179         Tobr (165,185]
```

Ejercicio 2: PCA

Realizar un análisis de componentes principales con los $n = 38$ virus del grupo Tobamovirus con las $p = 18$ características. Considerar las variables “tal cual” y repetir el análisis con las variables escaladas. Utilizar un máximo de 6 componentes. Realizar los gráficos y todas las explicaciones sobre este análisis.

```
set.seed(4567)


# Seleccionamos tobamoviruses
tobamovirus <- virus[which(virus$type == "Toba"),]

# Eliminamos duplicado
tobamovirus <- tobamovirus %>% distinct()

# Seleccionamos matriz de datos numéricos
toba_num <- select_if(tobamovirus, is.numeric)

# PCA con variables sin estandarizar
virus.pca.noscale <- prcomp(toba_num, scale = FALSE, center = FALSE)


# Proporción de la varianza total explicada por cada componente
fviz_eig(virus.pca.noscale, addlabels = TRUE, ncp = 6,
         main = "% Varianza (variables sin estandarizar)" + ylim(0, 100))
```




```
summary(virus.pca.noscale)$importance[,1:6]
```

	PC1	PC2	PC3	PC4	PC5	PC6
## Standard deviation	44.85171	5.611003	5.205442	2.757278	2.158259	1.843399
## Proportion of Variance	0.96112	0.015040	0.012950	0.003630	0.002230	0.001620
## Cumulative Proportion	0.96112	0.976160	0.989110	0.992740	0.994970	0.996590

```
# Gráfico de variables
fviz_pca_var(virus.pca.noscale, col.var = "contrib",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), repel = TRUE) +
  ggtitle("Variables PCA (variables sin estandarizar)")
```



```
# Diagrama de dispersión formado por los dos primeros ejes principales
fviz_pca_ind(virus.pca.noscale, col.ind = "cos2",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), repel = TRUE) +
  ggtitle("Individuos PCA (variables sin estandarizar)")
```



```
# Calculamos desviación estándar por columna
apply(toba_num, 2, sd)
```

```
##      V1      V2      V3      V4      V5      V6      V7      V8
## 2.4350744 3.5904290 3.8669185 4.2198643 1.3326516 1.5368864 3.2601739 0.4365910
##      V9      V10     V11     V12     V13     V14     V15     V16
## 2.3359397 1.4162238 1.3075990 1.4704292 1.1480084 1.7169973 0.5413223 0.9939361
##      V17     V18
## 1.2189238 0.8617030
```


El análisis de componentes principales realizado con las variables sin estandarizar muestra que un único componente explica el 96.1% de la varianza total, lo que representa casi el total de la variabilidad del conjunto de datos. Inicialmente, esto podría interpretarse como un indicio de alta colinealidad entre las variables. Sin embargo, al examinar sus desviaciones estándar, observamos que presentan rangos muy distintos. Esto indica que una o pocas variables tienen una varianza mucho mayor que el resto y estarían dominando el análisis. Por tanto, sería recomendable estandarizar las variables para que presenten una varianza unitaria, lo cual equivale a utilizar la matriz de correlaciones.

```
# PCA con variables estandarizadas
virus.pcscale <- prcomp(toba_num, scale = TRUE, center = TRUE)

summary(virus.pcscale)$importance[,1:6]

# Proporción de la varianza total explicada por cada componente
fviz_eig(virus.pcscale, addlabels = TRUE, ncp = 6,
         main = "% Varianza (variables estandarizadas)" + ylim(0, 31))
```


	PC1	PC2	PC3	PC4	PC5	PC6
## Standard deviation	2.31614	2.020127	1.446753	1.357126	1.146409	0.894448
## Proportion of Variance	0.29803	0.226720	0.116280	0.102320	0.073010	0.044450
## Cumulative Proportion	0.29803	0.524750	0.641030	0.743350	0.816360	0.860810




```
# Gráfico de variables
fviz_pca_var(virus.pcscale, col.var = "contrib",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), repel = TRUE) +
  ggtitle("Variables PCA (variables estandarizadas)")

# Diagrama de dispersión formado por los dos primeros ejes principales
fviz_pca_ind(virus.pcscale, col.ind = "cos2",
             gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), repel = TRUE) +
  ggtitle("Individuos PCA (variables estandarizadas)")
```

Variables PCA (variables estandarizadas)



Individuos PCA (variables estandarizadas)



En el PCA a partir de las variables estandarizadas, observamos que necesitamos al menos cinco componentes para explicar un 80% de la varianza total. Los dos primeros componentes representan un 52% de la varianza.

¿Cuales son las variables con mayor contribución a los dos primeros ejes en los dos análisis?
¿Se observan algunas agrupaciones de los virus? ¿Cuántas?

En el PCA con las variables sin estandarizar, las variables que contribuyen en mayor medida al primer componente son V1, V2, V3, V4 y V7, y al segundo componente, V3 y V4. Se observan dos agrupaciones, siendo una de ellas la que contiene la mayoría de los individuos.

En el PCA con las variables estandarizadas, las variables con mayor contribución al primer componente son V4, V8, V10, V13 y V14, y al segundo componente, V1, V2, V7, V15, V16 y V18. En este análisis, se identifican tres agrupaciones bien diferenciadas.

Identificar el virus que está entre dos grupos.

El individuo que se encuentra entre dos agrupaciones es el individuo 11.

Ejercicio 3: MDS clásico

Realizar un análisis MDS clásico con la distancia euclídea entre los virus del grupo Tobamovirus y con las variables sin escalar.

```
# Calculamos matriz de distancias euclídeas
dist.euc <- as.matrix(dist(toba_num))


# Análisis MDS clásico
mds <- cmdscale(dist.euc, eig=T)
```

Dibujar el gráfico de dispersión en dos dimensiones y valorar el resultado.


```
# Autovalores asociados a las dimensiones del MDS
lam <- mds$eig

# Bondad de ajuste
pb <- cumsum(lam) / sum(lam) * 100

# Porcentaje acumulado de varianza explicada
names(pb) <- paste("PC", 1:9)
pos <- barplot(pb[1:9],
               ylab = "Porcentaje",
               ylim = c(0, 110),
               main = "Porcentaje acumulado de varianza explicada")
text(x = pos, y = pb[1:9] + 5, labels = paste(round(pb[1:9], 1), "%"), cex = 0.9)
```




```
# Gráfico de dispersión con dos coordenadas
plot(mds$points, type = "n", xlab = "Coordenada 1", ylab = "Coordenada 2")
abline(h = 0, v = 0, lty = 4, col = "gray")
text(mds$points[,1], mds$points[,2], labels = rownames(dist.euc), cex=0.8)
title("MDS con distancia euclídea")
```

```
# Análisis MDS clásico con k=4
mds <- cmdscale(dist.euc, k = 4, eig = T)

# Representación dos a dos de algunas coordenadas principales
plot(mds$points[,2:3], type = "n", xlab = "PC2", ylab = "PC3")
abline(h = 0, v = 0, lty = 4, col = "gray")
text(mds$points[,2], mds$points[,3], labels = rownames(dist.euc), cex = 0.7)

plot(mds$points[,3:4], type = "n", xlab = "PC3", ylab = "PC4")
abline(h = 0, v = 0, lty = 4, col = "gray")
text(mds$points[,3], mds$points[,4], labels = rownames(dist.euc), cex = 0.7)
```




A pesar de que la representación en dos dimensiones (PC1 vs PC2) permite visualizar agrupaciones similares a las observadas en el PCA y conserva cierta estructura de los datos, el análisis del porcentaje acumulado

de varianza explicada indica que se requieren al menos cuatro coordenadas para capturar el 80% de la variabilidad y así representar adecuadamente la matriz de distancias. Al representar las coordenadas dos a dos, observamos que las agrupaciones se conservan en los gráficos que combinan la primera con la segunda coordenada, y la segunda con la tercera. Sin embargo, dicha estructura no se conserva al representar la tercera frente a la cuarta. Esto podría sugerir que la visualización en dos dimensiones no ofrece una representación adecuada de las distancias observadas originalmente.

Uno de los objetivos del estudio es hallar virus aislados o “alejados de cualquier grupo”. Para ello podemos utilizar el gráfico mean vs minimum de la función `disana()` del paquete `labdsv`. Los puntos más a la derecha y arriba nos indican observaciones alejadas de cualquier grupo.

```
outliers <- disana(dist.euc, panel = 3)

merge(outliers$min, outliers$mean, by = "row.names") %>%
  rename(min = x, mean = y) %>%
  ggplot(aes(x = min, y = mean, label = Row.names)) +
    theme(plot.title = element_text(hjust = 0.5)) +
    xlab("Minimum Dissimilarity") +
    ylab("Average Dissimilarity") +
    geom_point() +
    geom_text_repel(size = 3) +
    theme_bw()
```



El gráfico nos indica que los individuos 17 y 11 se encuentran alejados del resto de agrupaciones.

Ejercicio 4: MDS no métrico de Kruskal

Como las variables son puntuaciones no continuas, la distancia euclídea no parece la mejor elección. Entre las alternativas podemos considerar la distancia de Bray-Curtis. Realizar un MDS no métrico de Kruskal con la distancia de Bray-Curtis entre los virus del grupo Tobamovirus.

```
# Calculamos NMDS de Kruskal
nmds.krus <- metaMDS(toba_num, distance = "bray", engine = "monoMDS", trace = FALSE)
```

```
# Valor de estrés del NMDS de Kruskal
nmds.krus$stress
```

```
## [1] 0.1085195
```

¿Por qué debemos realizar un MDS no métrico, mejor que un MDS métrico clásico?

```
# Calculamos matriz de distancias de Bray-Curtis
dist.bc <- vegdist(toba_num, "bray")
```

```
# Comprobamos si las distancias son euclídeas
is.euclid(dist.bc, print = T)
```

```
## [1] 1.047444e-01 9.539792e-02 3.560893e-02 2.272146e-02 1.797421e-02
## [6] 1.478648e-02 1.136280e-02 6.971133e-03 4.876040e-03 3.459045e-03
## [11] 2.566606e-03 1.988308e-03 1.743473e-03 9.571683e-04 8.663537e-04
## [16] 8.186552e-04 5.832194e-04 4.505769e-04 1.716992e-04 -3.175655e-18
## [21] -1.796781e-05 -2.805617e-05 -8.949663e-05 -1.743615e-04 -1.801346e-04
## [26] -2.733519e-04 -4.525669e-04 -5.509785e-04 -8.163134e-04 -1.074607e-03
## [31] -1.153576e-03 -1.539601e-03 -1.926766e-03 -2.232525e-03 -2.787259e-03
## [36] -3.146594e-03 -4.671046e-03 -4.925289e-03
```

```
## [1] FALSE
```

El MDS no métrico (NMDS) se basa en los rangos de orden de las distancias, en lugar de en los valores absolutos, lo que lo hace adecuado para trabajar con matrices de distancias no euclídeas, como la de Bray-Curtis. A diferencia del MDS clásico, que asume que las distancias provienen de un espacio euclídeo, el NMDS no realiza esta suposición. Al comprobar la matriz de distancias de Bray-Curtis utilizada en nuestro análisis, observamos que no es euclídea. Por tanto, una representación de los puntos basada en el MDS clásico podría no mostrar adecuadamente las distancias entre los individuos.

Dibujar un scree plot sobre el stress para evaluar el número de ejes a considerar. Dibujar también un gráfico de Shepard para comparar las distancias originales y las propuestas por el MDS no métrico con 2 dimensiones.

```
# Scree plot
stress_values <- numeric(10)
for (k in 1:10) {
  fit <- metaMDS(toba_num, distance = "bray", engine = "monoMDS", trace = FALSE, k = k)
  stress_values[k] <- fit$stress
}
```

```
plot(1:10, stress_values, type = "b", pch = 19,
     xlab = "Número de dimensiones (k)", ylab = "Stress",
     main = "Scree plot - MDS no métrico (Kruskal)")
abline(h = 0.2, col = "red", lty = 2) # línea de referencia
```

```
# Gráfico de Shepard
stressplot(nmds.krus, main = "Gráfico de Shepard")
```

Scree plot – MDS no métrico (Kruskal)






Gráfico de Shepard



La correlación entre la disimilitud observada y la distancia de ordenación ($R^2 > 0.95$), así como un valor de estrés relativamente bajo, muestran en conjunto una buena precisión en la ordenación NMDS.

¿Cuántos subgrupos vemos en el gráfico de dispersión con 2 dimensiones?

```
# Gráfico de dispersión NMDS
plot(nmds.krus$points, type = "n", xlab = "PC1", ylab = "PC2")
abline(h = 0, v = 0, lty = 4, col = "gray")
text(nmds.krus$points[,1], nmds.krus$points[,2], labels = rownames(as.matrix(dist.bc)), cex = 0.5)
title(paste("MDS no métrico - Stress:", round(nmds.krus$stress, digits = 3)))
```



Algunas de las agrupaciones no se encuentran bien definidas, pero se pueden intuir 4 grupos.

Ejercicio 5: MDS no métrico de Sammon

Realizar un mapa no lineal de Sammon, es decir, otro tipo de MDS no métrico con la distancia de Bray-Curtis y los datos de Tobamovirus. Dibujar los gráficos del apartado anterior y responder las mismas cuestiones.

```
# MDS no métrico de Sammon
nmds.sa <- sammon(dist.bc, trace = FALSE)

# Scree plot
stress_values <- numeric(10)
for (k in 1:10) {
  fit <- sammon(dist.bc, k = k, trace = FALSE)
  stress_values[k] <- fit$stress
}

plot(1:10, stress_values, type = "b", pch = 19,
     xlab = "Número de dimensiones (k)", ylab = "Stress",
     main = "Scree plot - MDS no métrico (Sammon)")
abline(h = 0.2, col = "red", lty = 2) # línea de referencia

# Gráfico de Shepard
virus.sh <- Shepard(dist.bc, nmds.sa$points, p=2)

plot(virus.sh$x, virus.sh$y,
     xlab = "Distancia original (Bray-Curtis)",
     ylab = "Distancia proyectada",
     main = "Shepard plot",
     pch = 1, col = "blue")
lines(virus.sh$x, virus.sh$yf, col = "red", lwd = 2, lty = 1)

# Correlación de Spearman (ajuste no métrico)
```

```


r2 <- round(summary(lm(virus.sh$y ~ virus.sh$x))$r.squared, 3)

nonmetric_fit <- round(cor(virus.sh$x, virus.sh$y, method = "spearman"), 2)


text(x = 0.01, y = 0.22, adj = 0, cex = 0.9,
     labels = paste("Non-metric fit, R² =", nonmetric_fit, "\nLinear fit, R² =", r2))

```

Scree plot – MDS no métrico (Sammon)



Shepard plot




```

# Valor de stress del NMDS de Sammon
nmds.sa$stress

```

```
## [1] 0.03915509
```

```
plot(nmds.sa$points ,type = "n", xlab = "PC1", ylab = "PC2")
abline(h = 0, v = 0, lty = 4, col = "gray")
text(nmds.sa$points[,1], nmds.sa$points[,2], labels = rownames(as.matrix(dist.bc)), cex = 0.6)
title(paste("MDS no métrico - Stress:", round(nmds.sa$stress, digits = 3)))
```









Con el NMDS de Sammon, los valores de R^2 (ajuste lineal) y el ajuste no métrico son más bajos, lo que indica que las distancias proyectadas se ajustan peor a las distancias originales. Sin embargo, el valor del *stress* es menor que con el de Kruskal. Mientras que el método de Kruskal trata todas las distancias por igual, el método de Sammon enfatiza la preservación de las distancias pequeñas (ya que se normaliza dividiendo por la distancia correspondiente). Esto hace que, aunque los valores de ajuste sean inferiores, el valor de *stress* sea mejor y la visualización de los clústeres también. En el gráfico de dispersión, podemos observar también cuatro agrupaciones.

Ejercicio 6: *Projection Pursuit*

Por último vamos a utilizar una técnica que pretende hallar la proyección más “interesante” de un conjunto multivariante de datos. Se trata de la llamada *projection pursuit* (PP). Dibujar las proyecciones en dimensión 2 de cada uno de los índices. Comentar el resultado.

```
pp_def <- PP_Optimizer(toba_num)
pp_ft <- PP_Optimizer(toba_num, findex = "friedmantukey")
pp_ht <- PP_Optimizer(toba_num, findex = "hermite")
```




La técnica de *projection Pursuit* nos proporciona una forma algorítmica de visualizar la distribución de los datos en dimensiones inferiores, llevando a cabo diferentes rotaciones del mismo conjunto de datos. Esto nos ayuda a identificar qué proyecciones se desvían de una distribución gaussiana o normal, las cuales son las más “interesantes”. Esto nos permite revelar más detalles acerca de la estructura del conjunto de datos.

Los distintos índices permiten captar distintos tipos de estructuras, ya que cada uno es sensible a diferentes tipos de desviaciones. El índice por defecto en *projection Pursuit*, *holes*, busca detectar zonas de baja densidad en las proyecciones. Estas zonas pueden ayudar a delimitar los grupos o clústeres, siempre que estos se encuentren bien definidos y no exista demasiado ruido o valores atípicos.

Por otro lado, el índice de Friedman-Tukey está diseñado específicamente para revelar grupos o clústeres en los datos. El índice de Hermite, en cambio, prioriza las desviaciones de una distribución normal, particularmente en el comportamiento de las colas y, por tanto, es útil para detectar estructuras complejas en los datos.

El hecho de que no se observen clústeres claramente diferenciados en las proyecciones del índice por defecto nos indica que los posibles subgrupos no estarían claramente diferenciados. Al analizar las proyecciones obtenidas mediante el índice de Hermite, la existencia de varios picos en el histograma sugiere que las distribuciones de los subgrupos podrían ser distintas. De acuerdo al índice de Friedman-Tukey, se identifican tres subgrupos claramente definidos.



Ejercicio 7: MDS métrico con distancia ji-cuadrado

Otra distancia que se utiliza mucho con puntuaciones o frecuencias es la distancia ji-cuadrado. Comprobar que la matriz D de esta distancia sobre los datos de Tobamovirus verifica que

$$B = -\frac{1}{2}H(D \times D)H$$

es semidefinida positiva y, por lo tanto, la distancia es euclídea. La matriz H es la matriz de centrado.

```
# Calcular distancia ji-cuadrado
dist.chisq <- dist_chisquare(as.matrix(toba_num), diag = TRUE, upper = TRUE)

n <- nrow(as.matrix(dist.chisq))
unos <- rep(1,n)
I <- diag(unos)
```

```

# Calculamos matriz de centrado H y matriz de distancias al cuadrado D
H <- I - 1/n*(unos %*% t(unos))
D <- as.matrix(dist.chisq^2)

# Construimos matriz B
B <- -1/2*(H %*% D %*% H)
rownames(B) <- colnames(B) <- rownames(as.matrix(dist.chisq))

# Valores propios
evv <- eigen(B)$values; evv

## [1] 8.668570e-01 5.681162e-01 2.211095e-01 1.430053e-01 9.533694e-02
## [6] 6.709197e-02 6.288572e-02 4.362134e-02 3.240637e-02 2.729166e-02
## [11] 2.101454e-02 1.010739e-02 7.506026e-03 5.828872e-03 3.396658e-03
## [16] 2.613454e-03 2.061171e-03 6.375713e-17 5.549399e-17 3.768123e-17
## [21] 3.002110e-17 2.724583e-17 2.715073e-17 2.690969e-17 2.099321e-17
## [26] 1.961257e-17 1.715224e-17 7.639073e-18 3.608893e-18 -5.370014e-18
## [31] -7.076467e-18 -8.229838e-18 -1.968663e-17 -3.450245e-17 -4.205797e-17
## [36] -4.660017e-17 -7.593443e-17 -1.691260e-16

```

```

# Comprobamos si la matriz de distancias es euclídea
is.euclid(as.dist(dist.chisq))

```

```
## [1] TRUE
```

Una matriz simétrica es semidefinida positiva si y solo si todos sus autovalores son no negativos, o iguales a cero, lo que equivale a que la matriz sea euclídea. En nuestro caso, existen autovalores negativos, pero son numéricamente insignificantes. Por tanto, podemos confirmar que la matriz de distancias es semidefinida positiva.

Realizar un MDS con esta distancia y comentar el resultado respecto a los ejercicios anteriores.


```

# Análisis MDS
mds <- cmdscale(dist.chisq, eig = T)

# Gráfico de dispersión con dos coordenadas
plot(mds$points, type = "n", xlab = "PC1", ylab = "PC2")
abline(h = 0, v = 0, lty = 4, col = "gray")
text(mds$points[,1], mds$points[,2], labels = rownames(dist.euc), cex = 0.8)
title("MDS con distancia ji-cuadrado")

```

La representación obtenida mediante MDS con la distancia ji-cuadrado es similar a la obtenida con la distancia euclídea o mediante PCA. Igualmente se pueden observar 3 agrupaciones.



Ejercicio 8: Análisis de correspondencias

Realizar un análisis de correspondencias. Calcular la inercia total con los valores propios y las primeras inercias principales (en %). Dibujar una representación simétrica del CA y una representación solo de los virus. Comparar el resultado con el obtenido con la distancia ji-cuadrado.

```
# Tabla de frecuencias absolutas
tabla.N <- as.table(as.matrix(toba_num))

# Tabla de frecuencias relativas
tabla.F <- tabla.N / sum(tabla.N)

# Frecuencias relativas marginales
margin.f <- apply(tabla.F, 1, sum)
margin.c <- apply(tabla.F, 2, sum)

# Frecuencias relativas condicionadas por filas
tabla.P <- sweep(tabla.F, 1, margin.f, "/")

# Análisis de correspondencias
virus.ca <- ca(tabla.N)

# Calculamos la inercia total con los valores propios
sum(virus.ca$rowinertia)


## [1] 0.05739103

# Primeras inercias principales (en %)
eig.val <- head(get_eigenvalue(virus.ca)); eig.val


##          eigenvalue variance.percent cumulative.variance.percent
## Dim.1 0.022820794      39.763693      39.76369
```

```
## Dim.2 0.015021474      26.173905      65.93760
## Dim.3 0.005868514      10.225489      76.16309
## Dim.4 0.003773813       6.575614      82.73870
## Dim.5 0.002484388       4.328878      87.06758
## Dim.6 0.001771887       3.087393      90.15497
```

```
# Representación simétrica CA
fviz_ca_biplot(virus.ca, labelsize = 2) +
  xlim(-1, 0.3) + ylim(-0.3, 1) + ggtitle("Representación simétrica CA")
```



```
# Representación solo de los virus
fviz_ca_row(virus.ca, shape.row = 16, col.row = "cos2",
  gradient.cols = c("#00AFBB", "#E7B800", "#FC4E07"), labelsize = 2) +
  ggtitle("Representación virus")
```



Si comparamos la representación del análisis de correspondencias con los análisis anteriores, especialmente con los MDS y el PCA, observamos que los distintos virus presentan las mismas agrupaciones, sólo que el eje de la primera dimensión se encuentra invertido. Esto tiene sentido ya que la representación del CA se construye aplicando un MDS clásico a la matriz de distancias ji-cuadrado.

Los valores de las coordenadas de los puntos reflejan asociaciones entre las categorías de las filas y las columnas. Los puntos de las filas que aparecen próximos entre sí representan individuos con perfiles similares en cuanto a los residuos. Del mismo modo, los puntos de las columnas cercanos entre sí presentan perfiles similares en cuanto a las individuos. A su vez, la distancia entre los puntos de las filas y de las columnas nos indica que dicha combinación individuo/residuo ocurre más frecuentemente de lo esperado estadísticamente (considerando independencia estadística).

A pesar de que el valor de la inercia total es bajo, indicativo de una baja variabilidad entre los datos, según el gráfico, podemos ver que existen tres agrupaciones. Una de las agrupaciones está condicionada en mayor medida por los residuos V13 y V14, la segunda por los residuos V3, V14 y V16, y la tercera agrupación está asociada con el resto. También existen otros residuos, como V15, V10 y V8, alejados del resto, que parecen no estar asociados con ninguna agrupación e introducen variabilidad en el sistema.

Ejercicio 9: Conclusiones

Realizar un brevísimo informe con las conclusiones sobre la formación de grupos con los datos de Tobamovirus que se deducen de los ejercicios anteriores.

En este informe hemos realizado análisis utilizando tanto distancias euclídeas como no euclídeas para explorar las agrupaciones en los datos. Al aplicar distancias euclídeas, se observaron tres agrupaciones, mientras que en los análisis con distancias no euclídeas, se observaron cuatro. El hecho de que los análisis basados en distancias euclídeas no sean capaces de identificar el cuarto subgrupo indica que las relaciones entre los datos no son lineales o los datos presentan una estructura más compleja.

Bibliografía

- Lin, C. (2018). *Multidimensional Scaling (MDS)*. RPubS. <https://rpubs.com/YaPi/393252> Robin. (2023, November 27). *NMDS of Species Abundances*. RPubS. <https://rpubs.com/robinfromthahood/NMDS>
- Quebec Centre for Biodiversity Science. (n.d.). *Chapter 16 Nonmetric MultiDimensional Scaling*. <https://r.qcbs.ca/workshop09/book-en/nonmetric-multidimensional-scaling.html> Ossani, P.C., & Cirillo, M.A. (2025, April 19). *Package ‘Pursuit’*. CRAN. <https://cran.r-project.org/web/packages/Pursuit/Pursuit.pdf>
- Wikipedia. (2025, March 29). *Projection pursuit*. https://en.wikipedia.org/wiki/Projection_pursuit
- Melissa Van Bussel (ggnot2). (2021, February 15). *Projection Pursuit - High Level Overview*. YouTube. <https://www.youtube.com/watch?v=Os6ebW8Ay9k&t=280s>
- Wikipedia. (2024, February 15). *Matriz definida positiva*. https://es.wikipedia.org/wiki/Matriz_definida_positiva
- Kassambara. (2017, September 24). *CA - Correspondence Analysis in R: Essentials*. STHDA. <https://www.sthda.com/english/articles/31-principal-component-methods-in-r-practical-guide/113-ca-correspondence-analysis-in-r-essentials/#visualization-and-interpretation>
- Greenacre, M. (2008). *La práctica del análisis de correspondencias (Capítulo 4: Distancia ji-cuadrado e inercia)*. Fundación BBVA. https://www.fbbva.es/wp-content/uploads/2017/05/dat/greenacre_cap04.pdf
- MathWorks. (n.d.). *Mdscale: Nonclassical multidimensional scaling*. <https://www.mathworks.com/help/stats/mdscale.html>

Apéndice

```
# Projection Pursuit con los distintos índices
invisible(capture.output({
  pp_def <- PP_Optimizer(toba_num)
}))

invisible(capture.output({
  pp_ft <- PP_Optimizer(toba_num, findex = "friedmantukey")
}))

invisible(capture.output({
  pp_ht <- PP_Optimizer(toba_num, findex = "hermite")
}))

# Función para crear histograma de las proyecciones
crear_histograma <- function(objeto_proj, proyeccion, titulo, color){
  df <- as.data.frame(objeto_proj)

  ggplot(df, aes(x = .data[[paste0("Proyeccion ", proyeccion)]]) +
    geom_histogram(binwidth = 0.2, fill = color, color = "black", alpha = 0.7) +
    ggtitle(titulo) +
    xlab("Valor proyectado") +
    ylab("Frecuencia") +
    theme_minimal()
}

# Histogramas de las proyecciones
hist_defx <- crear_histograma(pp_def$proj.data, 1, "Índice por defecto - Proyección x", "skyblue")
hist_defy <- crear_histograma(pp_def$proj.data, 2, "Índice por defecto - Proyección y", "skyblue")

hist_ftx <- crear_histograma(pp_ft$proj.data, 1, "Índice Friedman-Tukey - Proyección x", "lightgreen")
hist_fty <- crear_histograma(pp_ft$proj.data, 2, "Índice Friedman-Tukey - Proyección y", "lightgreen")

hist_htx <- crear_histograma(pp_ht$proj.data, 1, "Índice Hermite - Proyección x", "darkred")
hist_h ty <- crear_histograma(pp_ht$proj.data, 2, "Índice Hermite - Proyección y", "darkred")

# Función para crear un gráfico de dispersión con las proyecciones
crear_pp_plot <- function(objeto_proj, titulo){

  df <- data.frame(
    x = objeto_proj[,1],
    y = objeto_proj[,2],
    label = rownames(objeto_proj))

  ggplot(df, aes(x = x, y = y, label = label)) +
    theme(plot.title = element_text(hjust = 0.6)) +
    ggtitle(titulo) +
    geom_point() +
    geom_text_repel(size = 3, max.overlaps = Inf) +
    xlab("Proyección 1") +
    ylab("Proyección 2") +
    theme_bw()
}
```

```

# Gráfico de dispersión con las proyecciones
ggplot_def <- crear_pp_plot(pp_def$proj.data, "Proyecciones - Índice por defecto")
ggplot_ft <- crear_pp_plot(pp_ft$proj.data, "Proyecciones - Índice Friedman-Tukey")
ggplot_ht <- crear_pp_plot(pp_ht$proj.data, "Proyecciones - Índice Hermite")

(figure <- ggarrange(hist_defx, hist_defy, hist_ftx, hist_f ty, hist_h tx, hist_h ty,
                     ncol = 2, nrow = 3))

(figure <- ggarrange(ggplot_def, ggplot_ft, ggplot_ht,
                     ncol = 1, nrow = 3, align = "hv"))

```